



算法平台工作进展

1. 整体功能概览







2.当前进展

2.1推理引擎GPU亲和支持

- 模型发布GPU亲和配置
- 推理服务GPU设备信息探测
- 推理发布亲和性支撑
- ☐ 同模型多GPU版本支持

2.2推理前后处理热更新

- 推理前后处理镜像注册
- 前后处理副本/镜像热更新
- ☐ CI/CD流程

2.3推理服务扩容

- 模型推理副本发布
- 前后处理HPA

2.4推理环境

- 推理环境 (T4 * 2) 部署
- 推理侧+算法平台中心侧数据同步

2.5推理性能研发自测

- 推理服务agent性能损耗摸底
- 水平扩容性能增长曲线摸底

算法测试结果